Белорусский государственный университет информатики и радиоэлектроники

Кафедра интеллектуальных информационных технологий

Лабораторная работа 1

Основы PyTorch и обучение полносвязной нейронной сети

Дисциплина: Интеллектуальный анализ данных

Датасет: Wine Quality (Red) - классификация качества красного вина

Содержание

1. Цель работы

2. Подготовка данных

3. Архитектура нейронной сети

4. Обучение модели

5. Визуализация результатов

6. Оценка модели и сравнение с классическими методами

7. Эксперимент: борьба с дисбалансом через SMOTE

8. Итоговое сравнение всех моделей

9. Выводы

1. Цель работы

Целью данной лабораторной работы является освоение основ библиотеки PyTorch: работа с тензорами, автоматическое вычисление градиентов, создание и обучение полносвязной нейронной сети для задачи классификации табличных данных. Результаты нейросети сравниваются с классическими методами машинного обучения, применёнными на том же датасете в предыдущем семестре.

2. Подготовка данных

2.1. Датасет

Используется датасет Wine Quality (Red) с платформы Kaggle. Датасет содержит 1599 объектов и 11 числовых признаков (кислотность, pH, содержание алкоголя и др.). Целевая переменная quality (оценка от 3 до 8) группируется в 3 класса:

- 0 - низкое качество (оценки 3-4): 40 объектов
- 1 - среднее качество (оценки 5-6): 780 объектов
- 2 - высокое качество (оценки 7-8): 179 объектов

Налицо сильный дисбаланс классов: класс 1 содержит в 19.5 раз больше объектов, чем класс 0.

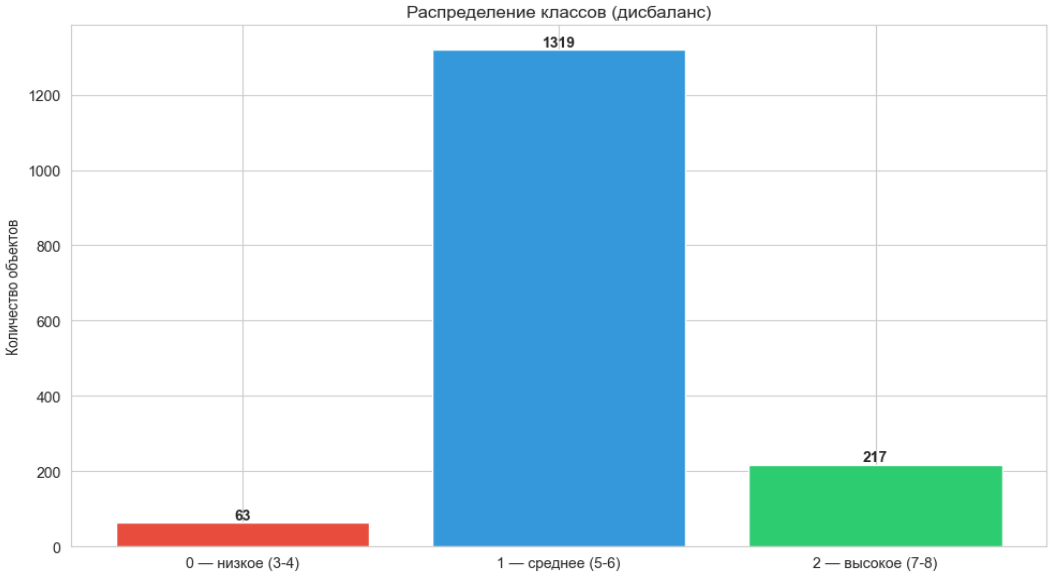

Рис. 1. Распределение классов в датасете (дисбаланс)

2.2. Разделение и предобработка

Данные разделены на обучающую (80%) и тестовую (20%) выборки с помощью train_test_split с параметром stratify для сохранения пропорций классов. Признаки стандартизированы через StandardScaler (fit на train, transform на обе выборки). Затем данные преобразованы в тензоры PyTorch (FloatTensor для признаков, LongTensor для меток).

Выборка	Класс 0	Класс 1	Класс 2	Всего
Train	50	1055	174	1279
Test	13	264	43	320

Таблица 1. Распределение классов по выборкам

3. Архитектура нейронной сети

Реализована полносвязная нейронная сеть (класс WineNet, наследник nn.Module) с тремя скрытыми слоями. Для борьбы с переобучением на малом датасете применены следующие техники регуляризации:

Слой	Размерность	Дополнительно
Linear + BatchNorm + ReLU + Dropout	11 -> 128	Dropout = 0.15
Linear + BatchNorm + ReLU + Dropout	128 -> 64	Dropout = 0.15
Linear + BatchNorm + ReLU	64 -> 32	-
Linear (выход)	32 -> 3	-

Таблица 2. Архитектура нейронной сети WineNet

Общее количество обучаемых параметров: 11 459. Использованные техники регуляризации:

- Batch Normalization - нормализация промежуточных представлений, ускоряет сходимость и стабилизирует обучение.
- Dropout (0.15) - случайное отключение 15% нейронов при обучении. Умеренное значение выбрано из-за малого объёма данных.
- L2-регуляризация (weight_decay=1e-4) - штраф за большие значения весов в оптимизаторе Adam.

3.1. Функция потерь и оптимизатор

Функция потерь: CrossEntropyLoss со смягчёнными весами классов. Веса вычислены как квадратный корень от обратной частоты класса, что позволяет учитывать дисбаланс без чрезмерного смещения в сторону миноритарных классов.

Класс	Кол-во (train)	Вес
0 - низкое	50	2.92
1 - среднее	1055	0.64
2 - высокое	174	1.57

Таблица 3. Веса классов (sqrt от обратной частоты)

Оптимизатор: Adam (lr=0.001, weight_decay=1e-4). Adam сочетает адаптивный learning rate с моментом, что эффективно для малых датасетов.

4. Обучение модели

Цикл обучения реализован с двумя улучшениями по сравнению со стандартным подходом:

- Early Stopping (patience=50) - если test loss не улучшается 50 эпох подряд, обучение останавливается, а веса модели восстанавливаются к лучшему состоянию.
- ReduceLROnPlateau - learning rate уменьшается в 2 раза при стагнации test loss в течение 15 эпох. Это позволяет модели точнее приблизиться к минимуму функции потерь.

Максимальное число эпох: 500. Обучение Weighted CE модели остановлено на эпохе 172 (лучшая эпоха: 122, test loss = 0.6557).

5. Визуализация результатов

5.1. Модель с Weighted CrossEntropyLoss

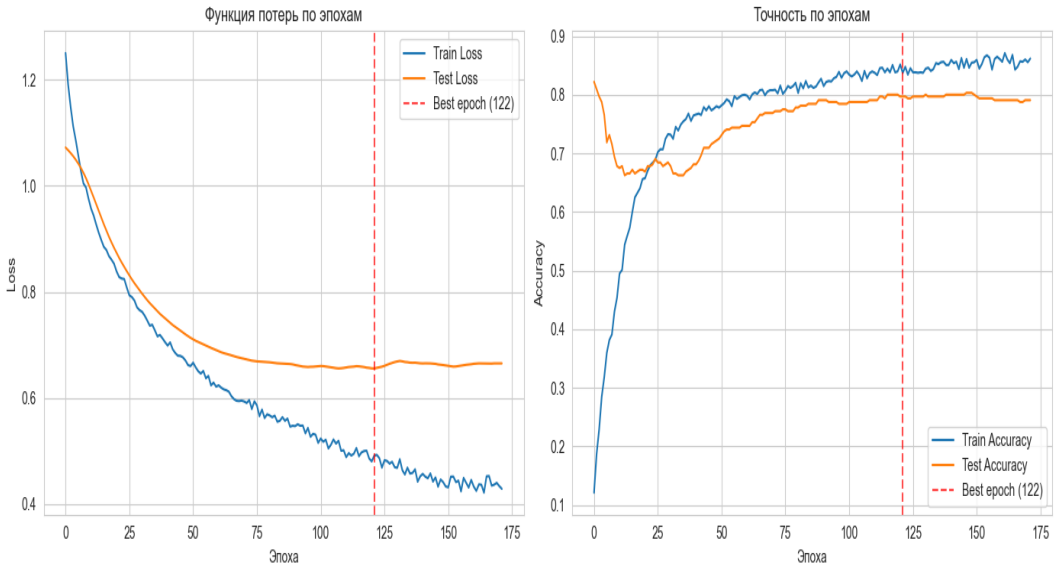

Рис. 2. Loss и Accuracy по эпохам (Weighted CE). Красная линия - лучшая эпоха

На графиках видно, что Early Stopping предотвратил переобучение: обучение остановлено до того, как test loss начал расти. Разрыв между train и test метриками умеренный благодаря Dropout и BatchNorm.

6. Оценка модели и сравнение с классическими методами

6.1. Метрики нейросети (Weighted CE)

Метрика	Значение
Accuracy	0.7969
F1-score (macro)	0.5820
ROC-AUC (macro)	0.8166

Таблица 4. Метрики нейросети (Weighted CE) на тестовой выборке

Classification Report:

Класс	Precision	Recall	F1-score	Support
0 - низкое (3-4)	0.22	0.31	0.26	13
1 - среднее (5-6)	0.92	0.82	0.87	264
2 - высокое (7-8)	0.51	0.79	0.62	43

Таблица 5. Classification Report по классам (Weighted CE)

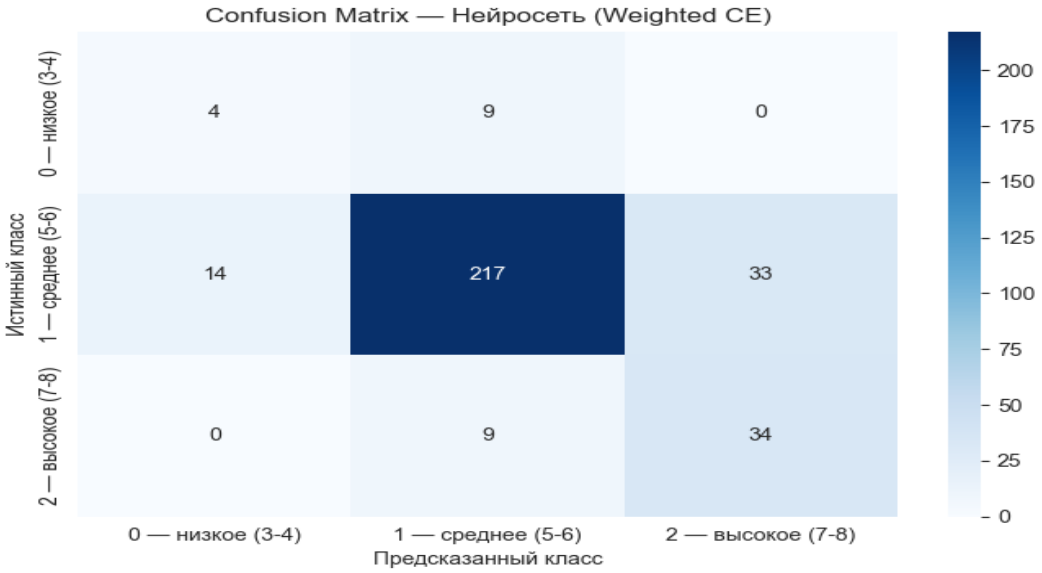

Рис. 3. Confusion Matrix (Weighted CE)

6.2. Сравнение с Gradient Boosting (прошлый семестр)

Модель	Accuracy	F1-score	ROC-AUC
Gradient Boosting (без баланс.)	0.8594	0.8465	0.8712
Gradient Boosting (oversampling)	0.8313	0.8360	0.8160
Gradient Boosting (undersampling)	0.5094	0.5712	0.8524

Модель	Accuracy	F1-score	ROC-AUC
Нейросеть (Weighted CE)	0.7969	0.5820	0.8166

Таблица 6. Сравнение нейросети с классическими методами

Gradient Boosting без балансировки показывает лучшие результаты (Accuracy=0.859, F1=0.847). Это ожидаемо: ансамблевые методы на деревьях решений, как правило, превосходят нейросети на малых табличных датасетах. Gradient Boosting последовательно строит деревья на ошибках предыдущих, что эффективно при ограниченном объёме данных. Нейросеть, в свою очередь, требует большего количества примеров для обобщения.

7. Эксперимент: борьба с дисбалансом через SMOTE

SMOTE (Synthetic Minority Over-sampling Technique) генерирует синтетические примеры для миноритарных классов путём интерполяции между существующими объектами и их ближайшими соседями в пространстве признаков. После применения SMOTE все три класса содержат по 1055 объектов.

	Класс 0	Класс 1	Класс 2
До SMOTE	50	1055	174
После SMOTE	1055	1055	1055

Таблица 7. Распределение классов до и после SMOTE

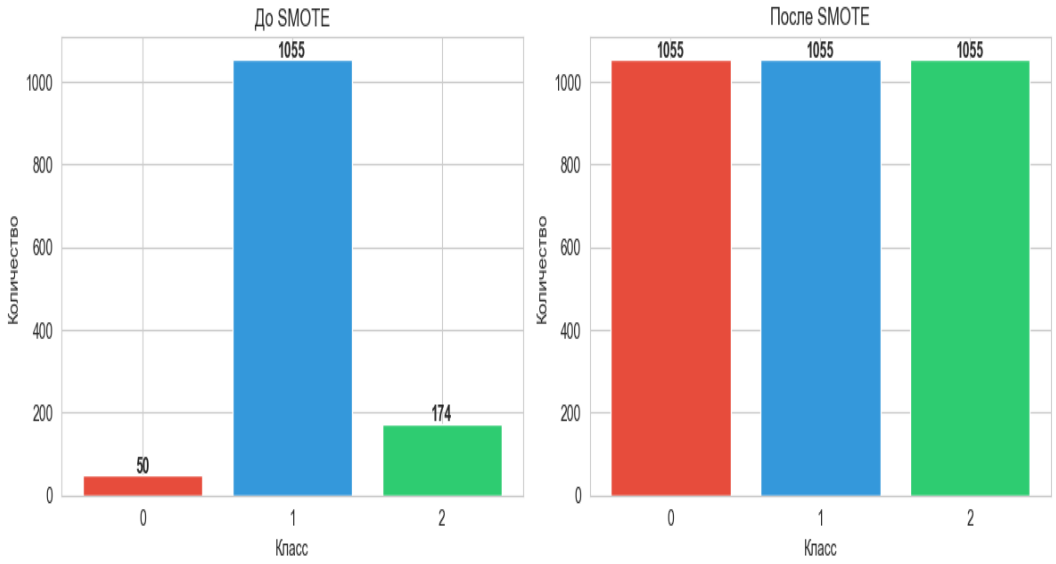

Рис. 4. Распределение классов до и после SMOTE

Нейросеть с той же архитектурой обучена на SMOTE-данных с обычным CrossEntropyLoss (без весов, т.к. данные уже сбалансированы). Обучение остановлено на эпохе 290 (лучшая эпоха: 240).

7.1. Графики обучения SMOTE-модели

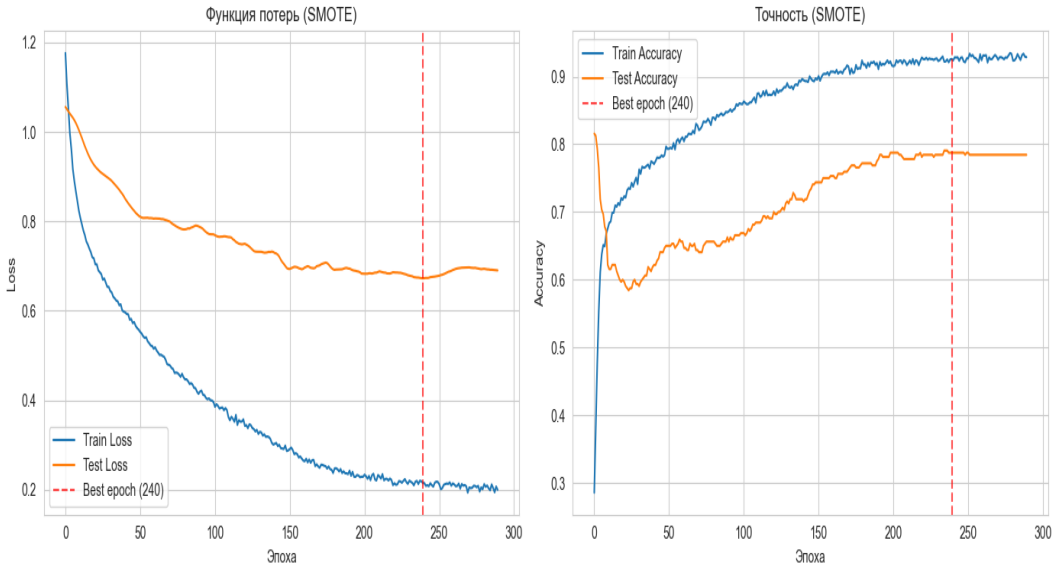

Рис. 5. Loss и Accuracy по эпохам (SMOTE)

7.2. Метрики SMOTE-модели

Метрика	Значение
Accuracy	0.7875
F1-score (macro)	0.6079
ROC-AUC (macro)	0.7723

Таблица 8. Метрики нейросети (SMOTE) на тестовой выборке

Класс	Precision	Recall	F1-score	Support
0 - низкое (3-4)	0.29	0.46	0.35	13
1 - среднее (5-6)	0.94	0.80	0.86	264
2 - высокое (7-8)	0.48	0.84	0.61	43

Таблица 9. Classification Report по классам (SMOTE)

Рис. 6. Confusion Matrix (SMOTE)

8. Итоговое сравнение всех моделей

Модель	Accuracy	F1 (macro)	ROC-AUC
Gradient Boosting (без баланс.)	0.8594	0.8465	0.8712
Gradient Boosting (oversampling)	0.8313	0.8360	0.8160
Gradient Boosting (undersampling)	0.5094	0.5712	0.8524
Нейросеть (Weighted CE)	0.7969	0.5820	0.8166
Нейросеть (SMOTE)	0.7875	0.6079	0.7723

Таблица 10. Итоговое сравнение всех моделей

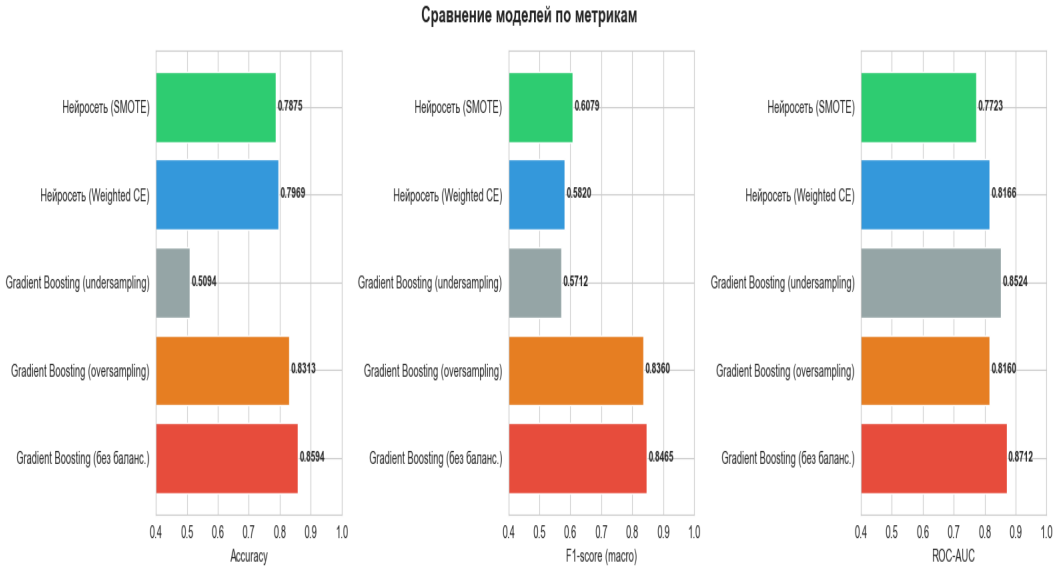

Рис. 7. Визуальное сравнение моделей по метрикам

9. Выводы

9.1. Нейросеть vs Gradient Boosting

Gradient Boosting без балансировки показал лучшие результаты на данном датасете (Accuracy=0.859, F1=0.847). Это закономерно по нескольким причинам:

- Датасет маленький (1599 объектов). Классические ансамблевые алгоритмы лучше работают на малых объёмах данных, т.к. каждое дерево решений обучается на подмножестве признаков и не требует большого количества примеров для обобщения.
- Gradient Boosting последовательно строит деревья на остатках предыдущих, что позволяет захватывать сложные нелинейные зависимости в табличных данных.
- Нейросети больше подвержены переобучению на малых выборках, даже при использовании регуляризации (Dropout, BatchNorm, Early Stopping).

9.2. Регуляризация

Применённые техники регуляризации (BatchNorm, Dropout 0.15, L2 weight_decay, Early Stopping, ReduceLROnPlateau) позволили существенно уменьшить разрыв между train и test метриками. Без этих техник модель сильно переобучалась: train loss падал, а test loss рос уже после 50 эпохи.

9.3. Борьба с дисбалансом

Weighted CrossEntropyLoss со смягчёнными весами (sqrt от обратной частоты) даёт Accuracy=0.797, но низкий macro F1=0.582 из-за слабого распознавания класса 0 (всего 13 объектов в тесте).

SMOTE даёт чуть ниже Accuracy=0.788, но лучший macro F1=0.608, т.к. синтетические примеры помогают модели лучше распознавать миноритарные классы.

Undersampling (прошлый семестр) привёл к катастрофическому падению Accuracy до 0.509, т.к. модель потеряла 95% данных мажоритарного класса.

9.4. Общий вывод

Для небольших табличных датасетов с дисбалансом классов градиентный бустинг остаётся сильным baseline. Нейросети могут быть конкурентоспособны при правильной регуляризации, но требуют большего объёма данных. SMOTE - эффективный метод балансировки, который улучшает macro F1 за счёт синтетической генерации миноритарных примеров. Weighted loss - более простая альтернатива, не требующая изменения данных.