Белорусский государственный университет информатики и радиоэлектроники

Кафедра интеллектуальных информационных технологий

Лабораторная работа 2

Свёрточные нейронные сети

Дисциплина: Интеллектуальный анализ данных

Датасет: EuroSAT - классификация спутниковых снимков земной поверхности

Содержание

1. Цель работы

2. Датасет EuroSAT

3. Подготовка данных

4. Задание 1. Baseline CNN

5. Задание 2. Улучшение модели

6. Таблица экспериментов

7. Выводы

1. Цель работы

Целью данной лабораторной работы является построение, обучение и улучшение свёрточной нейронной сети (CNN) для задачи многоклассовой классификации изображений. В ходе работы реализуется baseline-модель с обязательными компонентами (Conv2d, MaxPool2d, BatchNorm2d, Dropout, Linear), а затем проводится серия экспериментов по улучшению качества: аугментация данных, углубление архитектуры, подбор оптимизатора и learning rate.

2. Датасет EuroSAT

EuroSAT - датасет спутниковых снимков, полученных со спутника Sentinel-2 (программа Copernicus). Содержит 27 000 изображений размером 64x64 пикселей в формате RGB, распределённых по 10 классам земного покрова. Датасет опубликован в работе Helber et al. (2019, IEEE JSTARS).

Параметр	Значение
Количество изображений	27 000
Размер	64 x 64 пикселей
Каналы	RGB (3 канала)
Количество классов	10
Источник	torchvision.datasets.EuroSAT

Таблица 1. Характеристики датасета EuroSAT

Классы: AnnualCrop, Forest, HerbaceousVegetation, Highway, Industrial, Pasture, PermanentCrop, Residential, River, SeaLake.

Рис. 1. Примеры изображений EuroSAT (по 2 на класс)

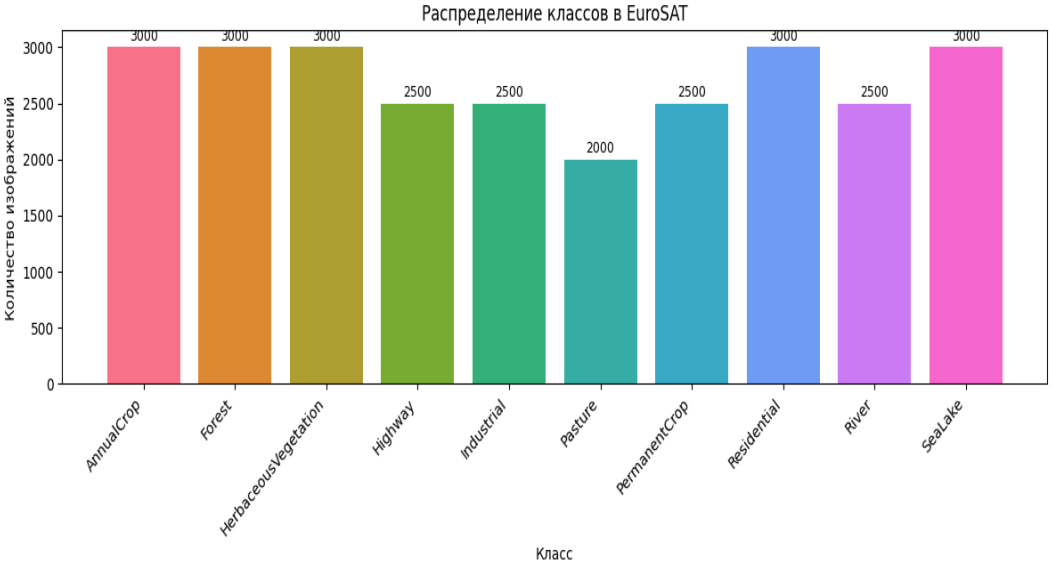

Рис. 2. Распределение классов в датасете

Датасет выбран вместо стандартных CIFAR-10 или Fashion-MNIST по ряду причин: снимки со спутника Sentinel-2 представляют практическую задачу дистанционного зондирования Земли; размер 64x64 идеально подходит под ограничение 128x128; встроенная загрузка через torchvision; 10 классов обеспечивают достаточную сложность задачи.

3. Подготовка данных

3.1. Разделение выборки

Датасет разделён на три части с помощью torch.utils.data.random_split с фиксированным seed=42 для воспроизводимости:

Выборка	Размер	Доля	Shuffle
Train	21 600	80%	True
Validation	2 700	10%	False
Test	2 700	10%	False

Таблица 2. Разделение данных

3.2. Нормализация

Статистики (mean и std) вычислены по train-выборке и применены ко всем трём выборкам:

Канал	Mean	Std
R	0.3439	0.0912
G	0.3800	0.0651
B	0.4077	0.0552

Таблица 3. Статистики нормализации (по train)

Batch size = 64 для всех DataLoader. Для train - shuffle=True, для val/test - shuffle=False.

4. Задание 1. Baseline CNN

4.1. Архитектура

Базовая модель (BaselineCNN) содержит все обязательные компоненты: свёрточные слои, пулинг, пакетная нормализация, функция активации, полносвязные слои, Dropout и выходной слой.

Блок	Слои	Выход
Block 1	Conv2d(3, 32, 3, pad=1) + BatchNorm2d + ReLU + MaxPool2d(2)	32 x 32 x 32
Block 2	Conv2d(32, 64, 3, pad=1) + BatchNorm2d + ReLU + MaxPool2d(2)	64 x 16 x 16
Classifier	Flatten + Linear(16384, 256) + ReLU + Dropout(0.3) + Linear(256, 10)	10

Таблица 4. Архитектура BaselineCNN

Dropout (p=0.3) размещён перед выходным полносвязным слоем в классификаторе. Это позволяет бороться с переобучением на этапе принятия решения, не мешая извлечению признаков в свёрточных слоях.

4.2. Обучение

Оптимизатор: Adam (lr=0.001). Функция потерь: CrossEntropyLoss. Обучение: 20 эпох с Early Stopping (patience=5). Лучшая Val Accuracy: 87.63% (эпоха 20).

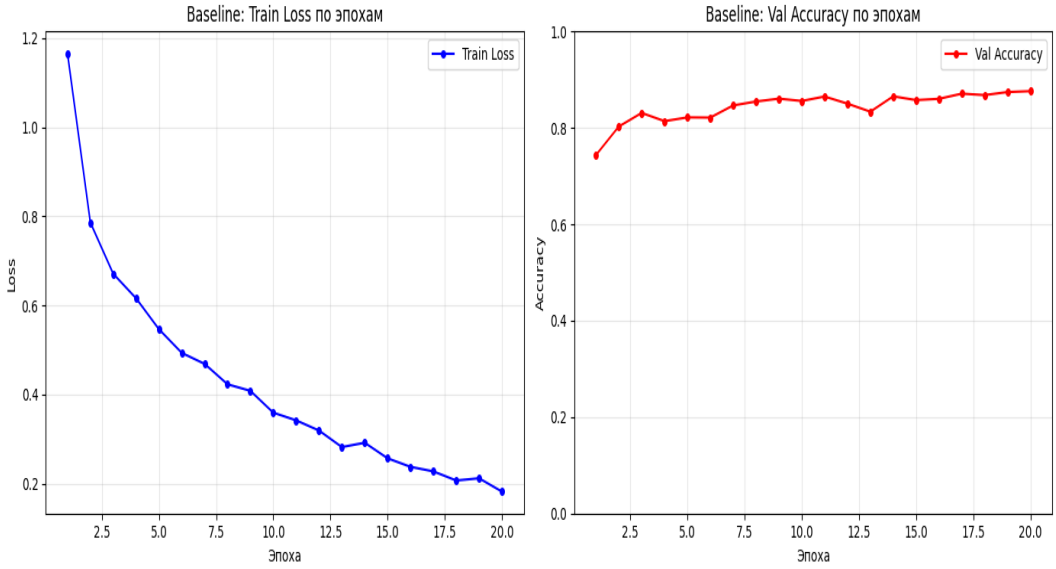

Рис. 3. Baseline CNN: Train Loss и Val Accuracy по эпохам

4.3. Оценка на тестовом наборе

Baseline Test Accuracy: 88.52%. Это в 8.85 раз выше случайного угадывания (10% для 10 классов).

Класс	Precision	Recall	F1-score	Support
AnnualCrop	0.88	0.94	0.91	300
Forest	0.97	0.96	0.96	297
HerbaceousVegetation	0.87	0.77	0.82	302
Highway	0.74	0.88	0.80	269
Industrial	0.94	0.91	0.92	257
Pasture	0.88	0.92	0.90	187
PermanentCrop	0.83	0.77	0.80	254
Residential	0.97	0.92	0.94	314
River	0.82	0.82	0.82	245
SeaLake	0.96	0.97	0.96	275

Таблица 5. Classification Report (Baseline, Test)

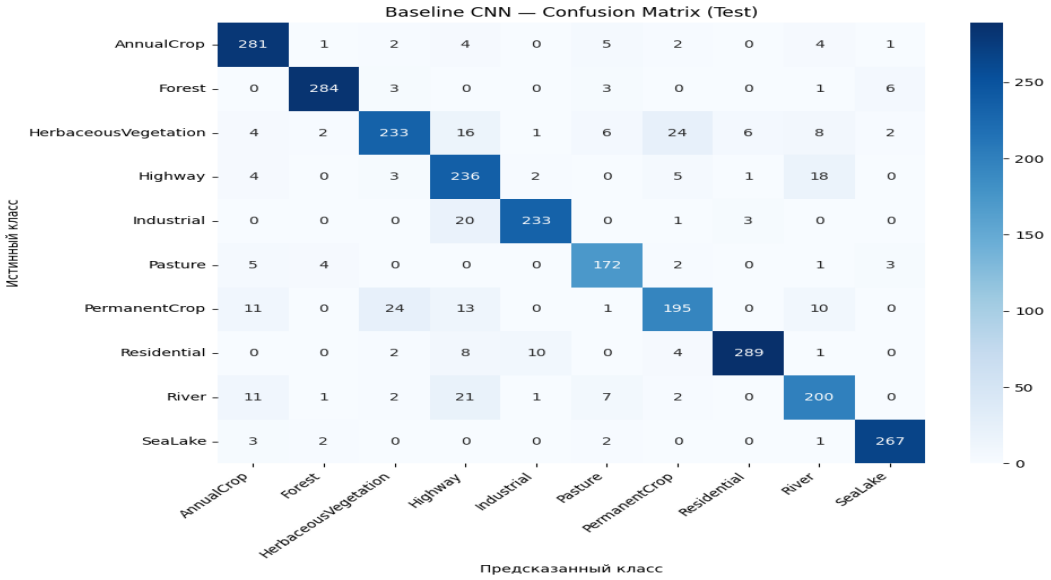

Рис. 4. Confusion Matrix (Baseline CNN, Test)

Слабые стороны baseline: путаница между Highway и River (оба имеют линейную структуру), а также между HerbaceousVegetation и PermanentCrop (схожая текстура растительности).

5. Задание 2. Улучшение модели

5.1. Аугментация данных

Для train-выборки реализована аугментация с четырьмя преобразованиями. Для val/test аугментация не применяется (только ToTensor + Normalize).

Преобразование	Обоснование
RandomHorizontalFlip	Снимки со спутника инвариантны к горизонтальному отражению (вид сверху)
RandomVerticalFlip	Вид сверху: вертикальное отражение не меняет семантику класса
RandomRotation(15)	Небольшие повороты моделируют разные углы орбиты спутника
ColorJitter(0.2, 0.2)	Вариации яркости и контраста моделируют разное время съёмки

Таблица 6. Аугментации и их обоснование

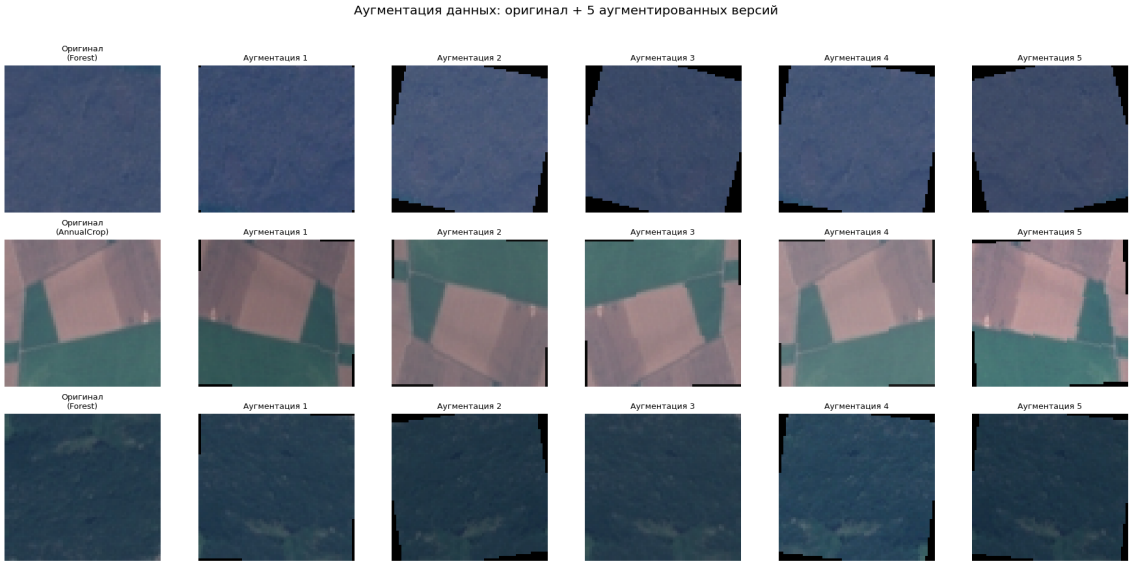

Рис. 5. Примеры аугментации (оригинал + 5 вариантов)

5.2. Серия экспериментов

Проведено 6 экспериментов с правилом "одно изменение за раз". Каждый эксперимент наследует лучшую конфигурацию предыдущего шага.

Эксперимент 1: + Аугментация. Добавление аугментации к BaselineCNN (2 conv блока). Val Acc = 86.96%, Test Acc = 87.44%. Незначительное ухудшение (-0.67% val) - модель с 2 conv блоками недостаточно ёмкая, чтобы извлечь пользу из расширенных данных.

Эксперимент 2: 3 conv блока. Добавление третьего свёрточного блока (128 фильтров). Val Acc = 92.81%, Test Acc = 93.15%. Самый большой прирост: +5.18% val acc. Дополнительный слой позволяет извлекать более сложные иерархические признаки.

Эксперимент 3: AdamW + weight_decay. Замена Adam на AdamW с L2-регуляризацией (weight_decay=1e-4). Val Acc = 92.37%, Test Acc = 92.93%. Незначительное изменение - при достаточном Dropout L2-регуляризация не даёт дополнительного эффекта.

Эксперимент 4: + LR Scheduler. Добавление ReduceLROnPlateau (patience=3, factor=0.5). Val Acc = 94.93%, Test Acc = 94.26%. Прирост +2.12% val acc: автоматическое снижение lr позволяет модели точнее сходиться на поздних эпохах.

Эксперимент 5: 4 conv блока + LeakyReLU + AdaptiveAvgPool. Архитектура: 32->64->128->256 фильтров, LeakyReLU(0.1), AdaptiveAvgPool2d(1), Dropout(0.5). Val Acc = 95.07%, Test Acc = 95.19%. Лучший результат. AdaptiveAvgPool уменьшил количество параметров с 2.2M до 423K, а LeakyReLU предотвратил проблему мёртвых нейронов.

Эксперимент 6: lr=0.0001. Снижение начального lr в 10 раз. Val Acc = 93.48%, Test Acc = 93.63%. Замедление сходимости без улучшения итогового качества.

6. Таблица экспериментов

No	Что изменено	Архитектура	Оптимизатор	Val Acc	Test Acc
0	Baseline (Задание 1)	2 conv + 1 fc	Adam, 0.001	87.63%	88.52%
1	+ Аугментация	2 conv + 1 fc	Adam, 0.001	86.96%	87.44%
2	3 conv блока	3 conv + 1 fc	Adam, 0.001	92.81%	93.15%
3	AdamW + weight_decay	3 conv + 1 fc	AdamW, wd=1e-4	92.37%	92.93%
4	+ LR Scheduler	3 conv + 1 fc	AdamW + RLROP	94.93%	94.26%
5	4 conv + LeakyReLU	4 conv + 1 fc	AdamW + RLROP	95.07%	95.19%
6	lr=0.0001	4 conv + 1 fc	AdamW + RLROP	93.48%	93.63%

Таблица 7. Результаты всех экспериментов

6.1. Финальная модель (Эксперимент 5)

Класс	Precision	Recall	F1-score	Support
AnnualCrop	0.94	0.96	0.95	300
Forest	0.97	0.98	0.97	297
HerbaceousVegetation	0.97	0.88	0.92	302
Highway	0.95	0.96	0.95	269
Industrial	0.96	0.96	0.96	257
Pasture	0.94	0.92	0.93	187
PermanentCrop	0.89	0.94	0.91	254
Residential	0.98	0.98	0.98	314
River	0.95	0.95	0.95	245
SeaLake	0.97	0.99	0.98	275

Таблица 8. Classification Report лучшей модели (Test)

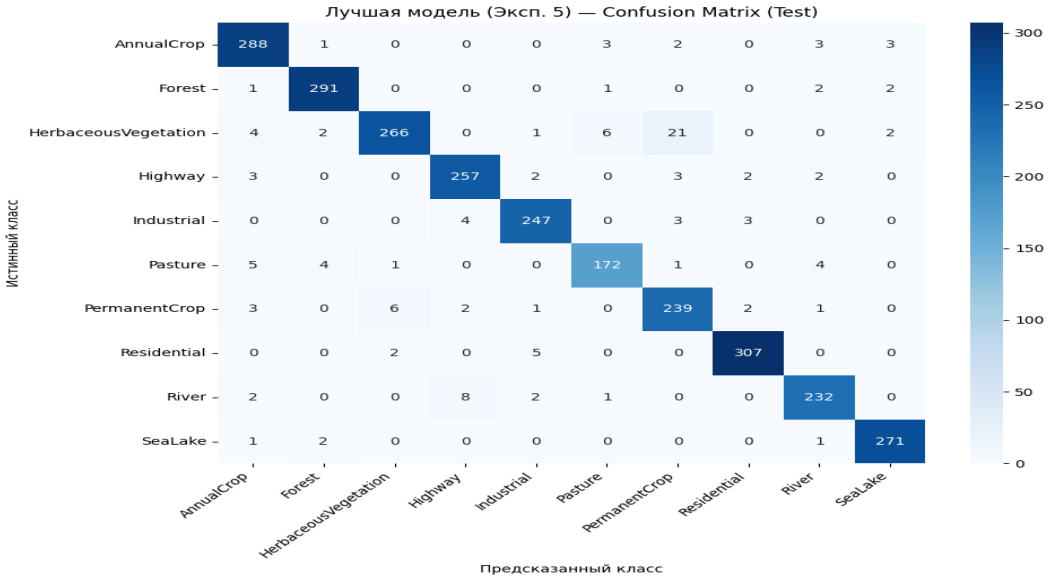

Рис. 6. Confusion Matrix лучшей модели (Эксперимент 5, Test)

6.2. Сравнение Baseline и лучшей модели

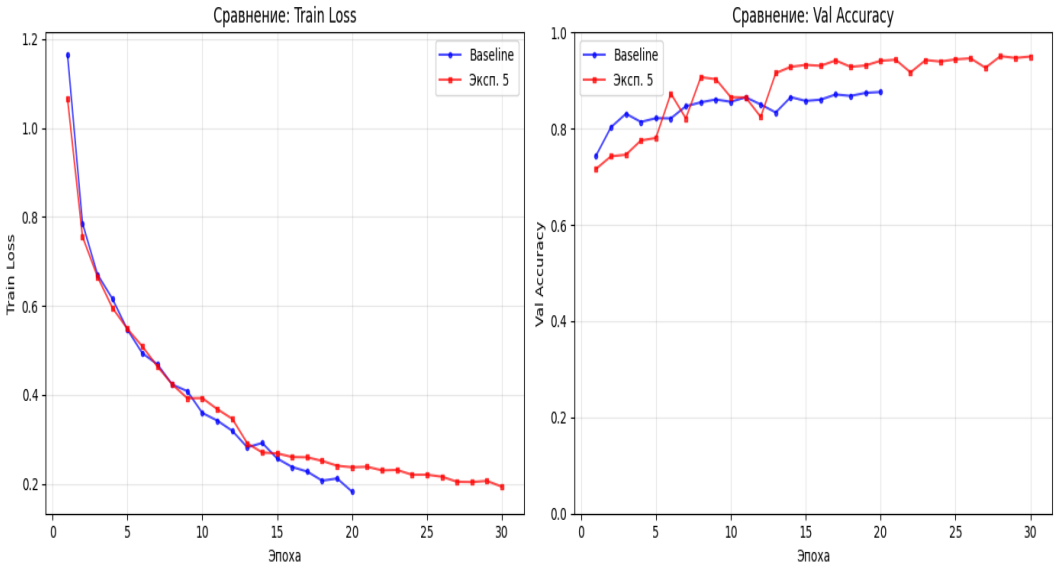

Рис. 7. Сравнение: Baseline vs лучшая модель (Train Loss и Val Accuracy)

7. Выводы

Baseline CNN (2 свёрточных блока, Adam lr=0.001) достиг 87.63% на валидации и 88.52% на тесте, что в 8.85 раза выше случайного угадывания (10%).

Последовательное улучшение модели позволило достичь 95.19% на тесте (+6.67% к baseline). Ключевые факторы улучшения:

- Углубление архитектуры (2 -> 4 свёрточных блока) дало наибольший прирост. Дополнительные слои позволяют модели извлекать более абстрактные признаки: от простых границ и текстур до сложных пространственных паттернов.
- LR Scheduler (ReduceLROnPlateau) позволил модели точнее сходиться на поздних этапах обучения, когда крупный learning rate приводит к осцилляциям.
- AdaptiveAvgPool2d(1) вместо фиксированного flatten уменьшил количество параметров с 2.2M до 423K, снизив риск переобучения.
- LeakyReLU(0.1) решил проблему мёртвых нейронов, позволяя градиентам проходить и через отрицательные значения.

Аугментация данных (Эксп. 1) не дала прироста на мелкой архитектуре (2 conv блока), но в сочетании с более глубокими моделями (Эксп. 2-5) стала частью pipeline, обеспечивающего лучшую обобщающую способность.

Уменьшение lr в 10 раз (Эксп. 6) привело к замедлению сходимости без улучшения качества, что подтверждает: начальный lr=0.001 с адаптивным снижением через ReduceLROnPlateau является оптимальной стратегией для данной задачи.