Белорусский государственный университет информатики и радиоэлектроники

Кафедра интеллектуальных информационных технологий

Лабораторная работа 3

Transfer Learning и интерпретируемость свёрточных нейронных сетей

Дисциплина: Интеллектуальный анализ данных

Датасет: STL-10. Классификация естественных объектов (10 классов, 96x96 RGB)

Содержание

1. Цель работы

2. Датасет STL-10

3. Подготовка данных

4. Задание 1. Сравнение трёх моделей

5. Задание 2. Интерпретируемость

6. Таблица сравнения

7. Выводы

1. Цель работы

Целью данной лабораторной работы является освоение техники переноса обучения (transfer learning) и методов интерпретируемости свёрточных нейронных сетей. В ходе работы сравниваются три подхода: обучение CNN с нуля, использование предобученной модели как фиксированного экстрактора признаков и полный fine-tuning. Также применяются методы визуализации для понимания внутренних представлений модели: визуализация фильтров, карт активаций и Grad-CAM.

2. Датасет STL-10

STL-10 - датасет из 10 классов естественных объектов (Coates, Ng, Lee, 2011). Содержит 5000 обучающих и 8000 тестовых изображений размером 96x96 пикселей в формате RGB. Малый объём обучающей выборки (500 изображений на класс) делает его идеальным для демонстрации эффективности transfer learning.

Параметр	Значение
Количество классов	10
Train изображений	5 000 (500 на класс)
Test изображений	8 000 (800 на класс)
Размер	96 x 96 пикселей
Каналы	RGB (3 канала)
Источник	torchvision.datasets.STL10

Таблица 1. Характеристики датасета STL-10

Классы: airplane, bird, car, cat, deer, dog, horse, monkey, ship, truck.

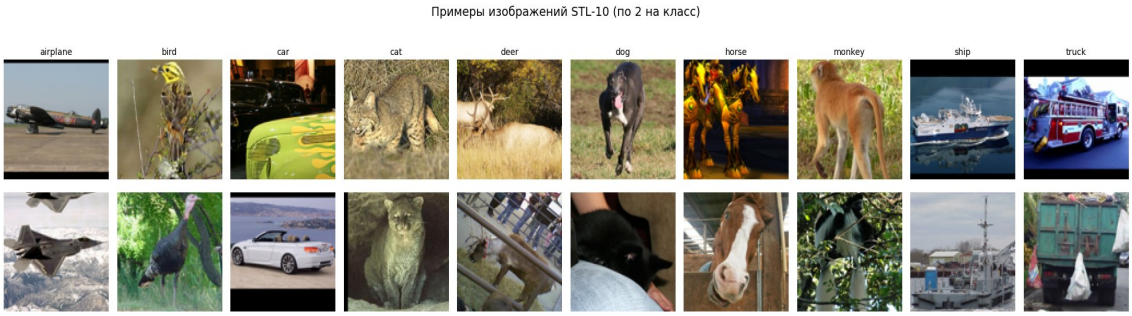

Рис. 1. Примеры изображений STL-10 (по 2 на класс)

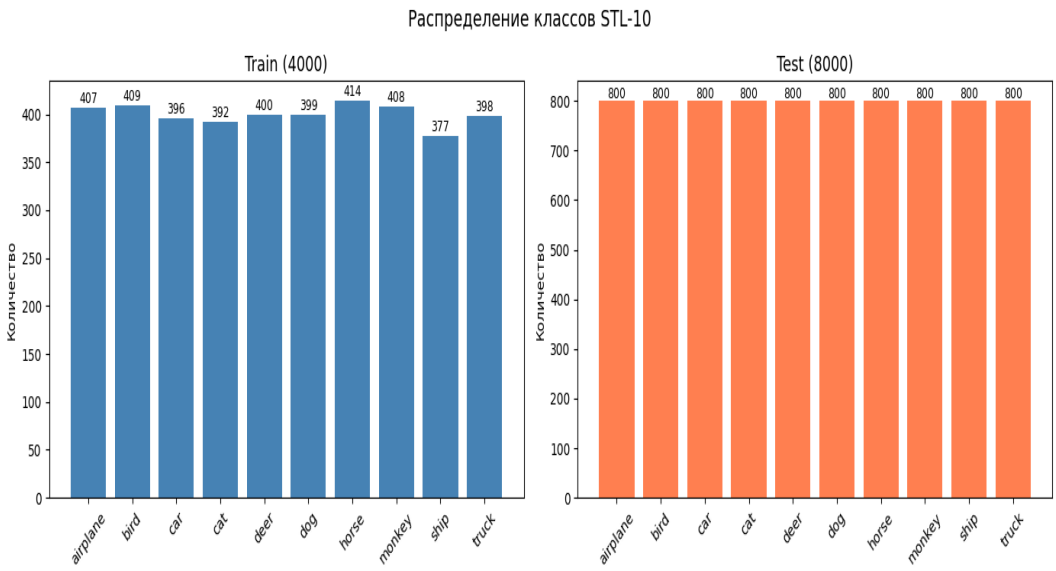

Рис. 2. Распределение классов в train и test выборках

2.1. Обоснование выбора датасета

В лабораторной работе 2 на датасете EuroSAT (27 000 спутниковых снимков) лучшая модель достигла 95.19% accuracy. При такой высокой точности transfer learning не может продемонстрировать значимое улучшение. STL-10 выбран по ряду причин:

- Малый training set (5 000 изображений) создаёт условия, при которых transfer learning критически важен: предобученные на ImageNet фичи компенсируют нехватку данных.
- 10 классов обеспечивают наглядную confusion matrix и удобный анализ ошибок.
- Изображения 96x96 RGB удовлетворяют ограничению <= 128x128.
- Классы естественных объектов (животные, транспорт) хорошо представлены в ImageNet, что обеспечивает эффективный перенос знаний.

3. Подготовка данных

3.1. Разделение выборки

Train-выборка (5 000 изображений) разделена на train и validation с помощью torch.utils.data.random_split с seed=42:

Выборка	Размер	Назначение
Train	4 000	Обучение моделей
Validation	1 000	Подбор гиперпараметров, early stopping
Test	8 000	Финальная оценка

Таблица 2. Разделение данных

3.2. Нормализация

Для модели A (обучение с нуля) нормализация выполнена по статистикам train-выборки. Для моделей B и C (pretrained) использованы статистики ImageNet, так как веса ResNet18 оптимизированы для данных с такой нормализацией.

Статистики	R	G	B
Dataset mean	0.4467	0.4397	0.4061
Dataset std	0.2600	0.2561	0.2706
ImageNet mean	0.485	0.456	0.406
ImageNet std	0.229	0.224	0.225

Таблица 3. Статистики нормализации

3.3. Аугментация и resize

Модель A работает с исходным размером 96x96. Модели B и C получают изображения 224x224 (стандарт для предобученных моделей torchvision). Аугментация для train: RandomHorizontalFlip, RandomRotation(15), ColorJitter(brightness=0.2, contrast=0.2). Для val/test аугментация не применяется.

4. Задание 1. Сравнение трёх моделей

4.1. Модель A: обучение с нуля (CNN_4Block)

Архитектура из лабораторной работы 2: 4 свёрточных блока (Conv2d + BatchNorm2d + LeakyReLU + MaxPool2d/AdaptiveAvgPool2d), классификатор с Dropout(0.5). На EuroSAT (21 600 train) давала 95.19%, на STL-10 (4 000 train) результат значительно ниже.

Блок	Слои	Выход
Block 1	Conv2d(3,32,3,pad=1) + BN + LeakyReLU + MaxPool2d(2)	32 x 48 x 48
Block 2	Conv2d(32,64,3,pad=1) + BN + LeakyReLU + MaxPool2d(2)	64 x 24 x 24
Block 3	Conv2d(64,128,3,pad=1) + BN + LeakyReLU + MaxPool2d(2)	128 x 12 x 12
Block 4	Conv2d(128,256,3,pad=1) + BN + LeakyReLU + AdaptiveAvgPool(1)	256 x 1 x 1
Classifier	Linear(256,128) + LeakyReLU + Dropout(0.5) + Linear(128,10)	10

Таблица 4. Архитектура CNN_4Block (Модель A)

Обучение: AdamW (lr=0.001, weight_decay=1e-4), ReduceLROnPlateau (patience=3), 30 эпох. Параметров: 423 562. Результат: Val Accuracy = 65.90%, Test Accuracy = 65.46%.

4.2. Модель B: ResNet18 с замороженными слоями

ResNet18, предобученная на ImageNet. Все свёрточные слои заморожены (requires_grad=False). Заменена классификационная голова: Linear(512, 256) + ReLU + Dropout(0.5) + Linear(256, 10). Обучаются только 133 898 параметров (1.2% от общих 11 310 410).

Обучение: Adam (lr=0.001), 20 эпох (early stopping на эпохе 9). Результат: Val Accuracy = 92.80%, Test Accuracy = 92.39%. Прирост +26.93% по сравнению с моделью A.

4.3. Модель C: полный Fine-tuning

ResNet18 с такой же новой головой, но все параметры обучаемы. Дифференцированный learning rate: backbone lr=1e-4, голова lr=1e-3. Это позволяет тонко адаптировать предобученные фичи, не разрушая их.

Обучение: Adam с раздельными lr, ReduceLROnPlateau, 20 эпох. Обучаемых параметров: 11 310 410 (все). Результат: Val Accuracy = 95.20%, Test Accuracy = 95.14%. Прирост +29.68% по сравнению с моделью A, +2.75% по сравнению с моделью B.

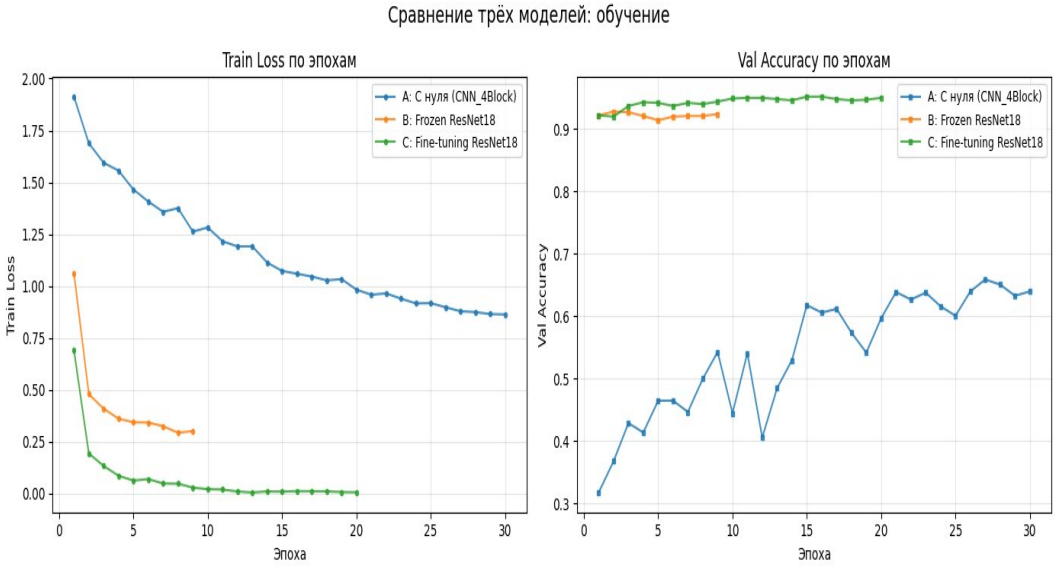

Рис. 3. Сравнение обучения трёх моделей: Train Loss и Val Accuracy

4.4. Classification Report лучшей модели (Модель C)

Класс	Precision	Recall	F1-score	Support
airplane	0.98	0.96	0.97	800
bird	0.97	0.96	0.96	800
car	0.95	0.97	0.96	800
cat	0.90	0.93	0.91	800
deer	0.96	0.95	0.95	800
dog	0.92	0.92	0.92	800
horse	0.98	0.93	0.95	800
monkey	0.95	0.97	0.96	800
ship	0.97	0.97	0.97	800
truck	0.95	0.96	0.96	800

Таблица 5. Classification Report модели C (Fine-tuning, Test)

5. Задание 2. Интерпретируемость

5.1. Визуализация фильтров первого свёрточного слоя

ResNet18.conv1 содержит 64 фильтра размером 7x7x3 (RGB). Каждый фильтр детектирует определённый базовый паттерн во входном изображении.

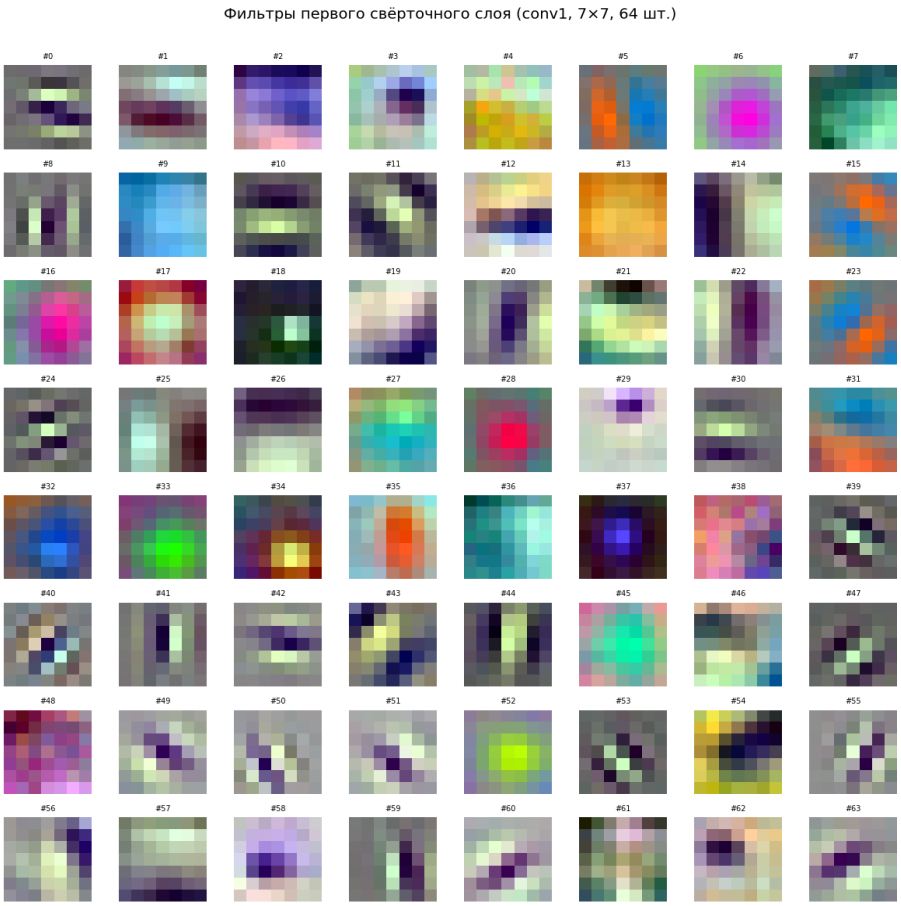

Рис. 4. 64 фильтра первого свёрточного слоя (conv1, 7x7)

Фильтры демонстрируют типичные для первого слоя CNN паттерны: Gabor-подобные детекторы границ различной ориентации (горизонтальные, вертикальные, диагональные), цветовые градиенты (переходы между цветовыми каналами) и текстурные детекторы. Эти базовые фильтры формируют основу для иерархического извлечения более сложных признаков в глубоких слоях сети.

5.2. Визуализация карт активаций

Промежуточные активации извлечены через forward hooks после layer1 (ранний слой, 64 канала, 56x56) и layer3 (глубокий слой, 256 каналов, 14x14) для трёх тестовых изображений.

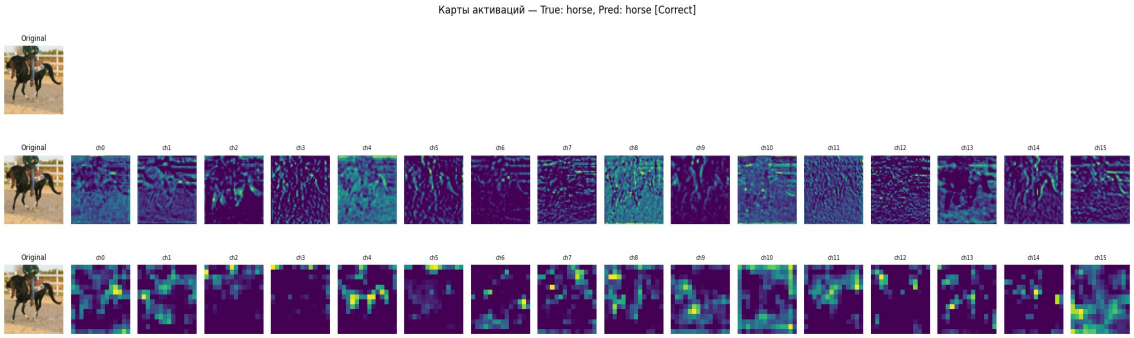

Рис. 5. Карты активаций (layer1 и layer3) для изображения horse

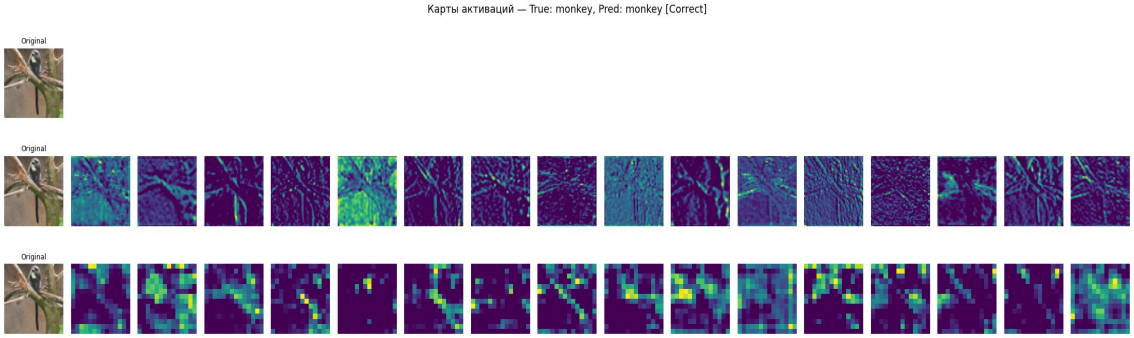

Рис. 6. Карты активаций для изображения monkey

Layer1 (ранний) выделяет низкоуровневые признаки: границы объектов, контрастные переходы, текстуры поверхностей. Layer3 (глубокий) реагирует на высокоуровневые семантические области: части тела животных, контуры объектов, отличительные формы. Это подтверждает иерархическую природу представлений в CNN.

5.3. Grad-CAM

Grad-CAM (Gradient-weighted Class Activation Mapping, Selvaraju et al., 2017) визуализирует области изображения, наиболее важные для решения модели. Применён к последнему свёрточному блоку ResNet18 (layer4[-1]).

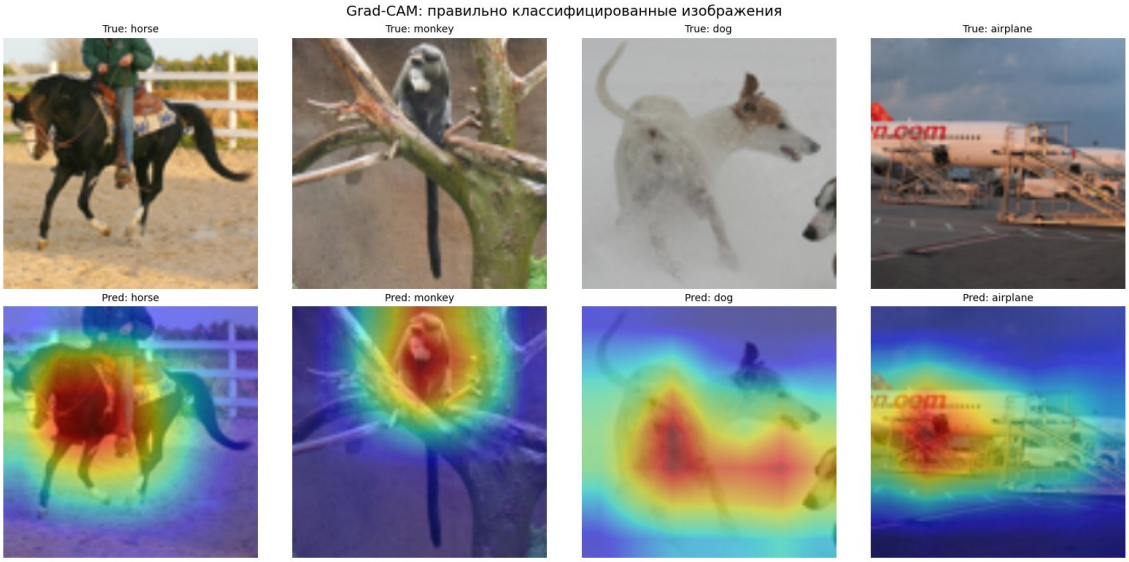

Рис. 7. Grad-CAM для правильно классифицированных изображений

Для правильно классифицированных изображений модель фокусируется непосредственно на объекте: на корпусе самолёта, теле животного, кузове автомобиля. Тепловая карта точно совпадает с расположением целевого объекта.

Рис. 8. Grad-CAM для неправильно классифицированных изображений

Для ошибочных предсказаний Grad-CAM показывает, что модель фокусируется на нерелевантных областях (фон, похожие текстуры) или на частях объекта, которые визуально схожи между путаемыми классами.

Рис. 9. Сравнение Grad-CAM: predicted (cat) vs true (bird) класс

При сравнении тепловых карт для predicted и true классов видно, что модель обращает внимание на разные области изображения при оценке разных гипотез. Для predicted класса 'cat' фокус на текстуре, для true класса 'bird' - на контуре.

5.4. Анализ ошибок

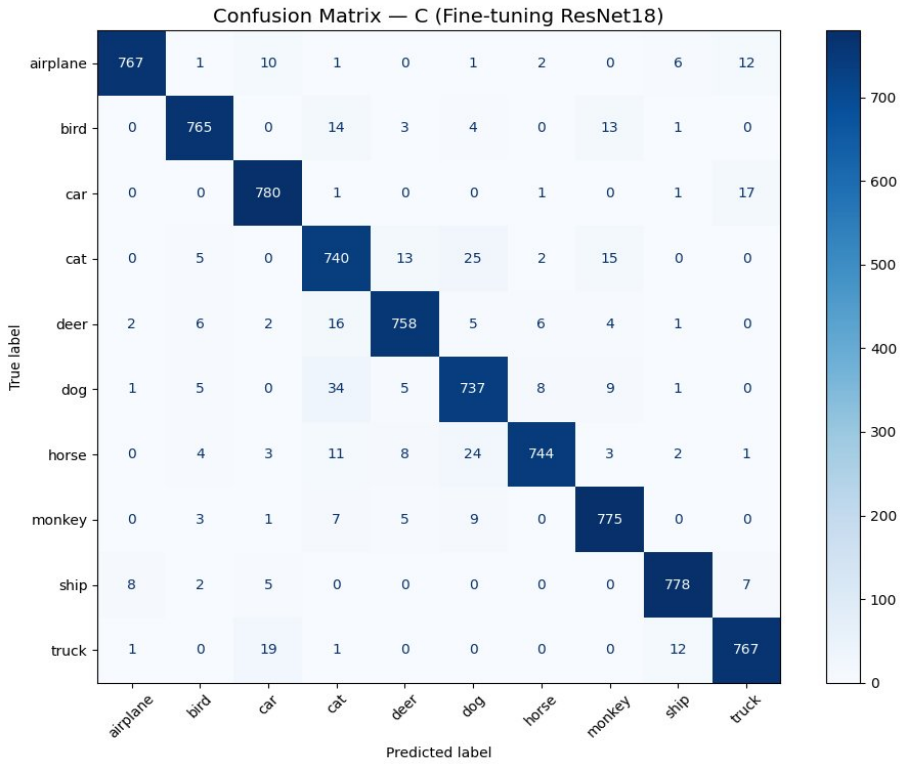

Рис. 10. Confusion Matrix модели C (Fine-tuning ResNet18, Test)

Топ-3 наиболее частые ошибки:

#	True класс	Predicted класс	Кол-во ошибок	Возможная причина
1	dog	cat	34	Похожая форма тела, текстура шерсти, четвероногие
2	cat	dog	25	Обратная путаница: схожие визуальные признаки
3	horse	dog	24	Четвероногие, схожая поза, текстура

Таблица 6. Топ-3 наиболее частые ошибки классификации

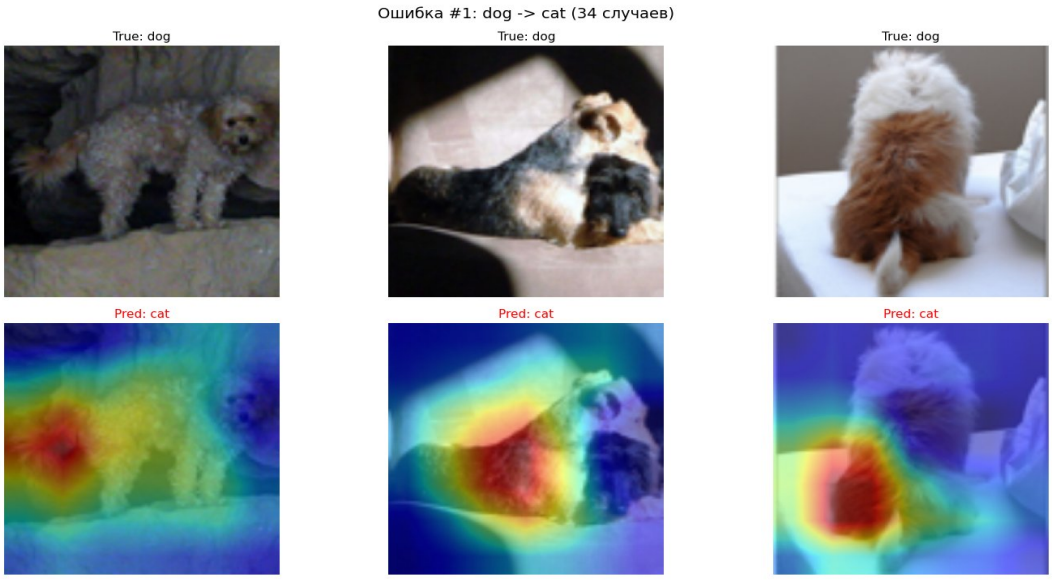

Рис. 11. Grad-CAM для ошибки dog -> cat (3 примера)

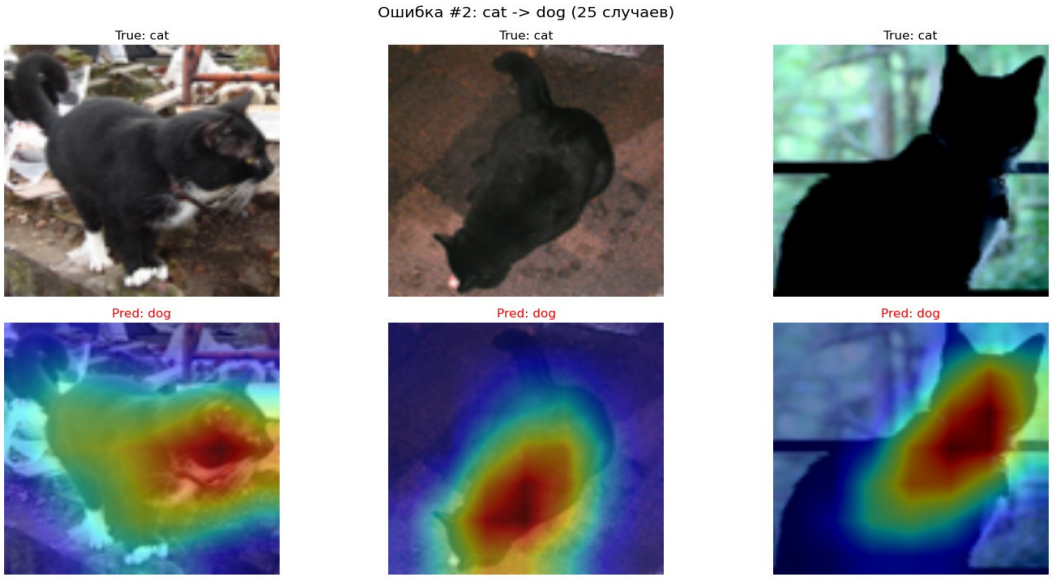

Рис. 12. Grad-CAM для ошибки cat -> dog (3 примера)

Grad-CAM на примерах ошибок показывает, что модель фокусируется на текстуре шерсти и общей форме тела, а не на специфичных для класса признаках (форма ушей, морды, пропорции тела). Это объясняет двустороннюю путаницу между dog и cat (34+25=59 ошибок) и одностороннюю путаницу horse -> dog (24 ошибки). Многие ошибочные примеры объективно сложны: нетипичные ракурсы, мелкий объект на фоне, нечёткое изображение.

6. Таблица сравнения

Модель	Режим	Обуч. парам.	Время/ эп.	Эпох	Val Acc	Test Acc
A: CNN_4Block	С нуля	423 562	6.1с	30	65.90%	65.46%
B: ResNet18	Frozen backbone	133 898	15.8с	9	92.80%	92.39%
C: ResNet18	Fine-tuning	11 310 410	18.3с	20	95.20%	95.14%

Таблица 7. Сравнение трёх моделей на STL-10

Сравнение с лабораторной работой 2 (EuroSAT):

Метрика	Lab 2 (EuroSAT)	Lab 3 (STL-10)
Датасет	27 000 спутн. снимков, 64x64	5 000 фотографий, 96x96
CNN с нуля	95.19% (4 conv)	65.46% (4 conv)
Best Transfer Learning	- (не применялся)	95.14% (ResNet18 FT)
Прирост от TL	-	+29.68%

Таблица 8. Сравнение с лабораторной работой 2

7. Выводы

Transfer learning продемонстрировал критическую важность при ограниченном объёме данных. На STL-10 (4000 train) обучение с нуля дало лишь 65.46%, тогда как fine-tuning предобученной ResNet18 достиг 95.14% (+29.68%). Ключевые результаты:

- Frozen backbone (модель B, 92.39%) требует обучения лишь 1.2% параметров (133K из 11.3M) и сходится за 9 эпох. Это наиболее экономичный вариант, подходящий для быстрого прототипирования и ситуаций с ограниченными вычислительными ресурсами.
- Full fine-tuning (модель C, 95.14%) даёт наилучший результат за счёт адаптации всех слоёв к целевому домену. Дифференцированный lr (backbone 1e-4, head 1e-3) предотвращает разрушение предобученных представлений.
- Обучение с нуля (модель A, 65.46%) на 4000 изображениях недостаточно для построения качественных иерархических представлений. Модель не может извлечь сложные признаки без предварительного обучения на крупном датасете.

Методы интерпретируемости подтвердили осмысленность решений модели:

- Фильтры conv1 содержат Gabor-подобные детекторы границ и цветовые градиенты; ранние слои выделяют границы и текстуры; глубокие слои реагируют на семантические области.
- Grad-CAM показал, что для правильных предсказаний модель фокусируется на объекте, а для ошибок фокус смещается на нерелевантные области или текстуры, общие для путаемых классов (dog, cat, horse).
- Наиболее частые ошибки (dog-cat: 59, horse-dog: 24) объясняются визуальным сходством четвероногих животных. Grad-CAM подтверждает, что модель опирается на текстуру шерсти, а не на специфичные формы.